

GUIA COMPLETO DE PROVA

Metodos Matematicos para Analise de Dados

UNIFEI - 4o semestre

OBJETIVO Material de consulta operacional: identificar o tipo de questao, escolher a tecnica correta, adaptar um template pronto e interpretar o resultado. Consolidado a partir dos exercicios/notebooks, slides e da Ativ_Avaliativa1.ipynb.

PRIORIDADE DE PROVA Distribuicao Normal, leitura/comparacao de graficos, filtros com Pandas, groupby/crosstab e os padroes da Atividade Avaliativa 1.

Use Ctrl+F no PDF para procurar termos como: cdf, ppf, boxplot, normalize=index, pelo menos, histograma, groupby, outlier, normal, poisson, binomial.

Edicao de consulta rapida - 2026

Como usar este PDF na prova

1. Leia o verbo principal do enunciado: calcular, comparar, filtrar, agrupar, representar, estimar ou interpretar.
2. Identifique o tipo de variavel: categorica, quantitativa discreta, quantitativa continua ou temporal.
3. Se for probabilidade, traduza imediatamente as palavras do enunciado para PMF/CDF/SF/PPF.
4. Se for dados, filtre primeiro; depois agregue; somente depois monte o grafico.
5. Ao comparar graficos, nao descreva so a aparencia: compare centro, dispersao, formato e outliers.
6. Na Normal, desenhe mentalmente a curva e marque a area pedida antes de escrever o codigo.

Mapa do material

Bloco	Conteudo
A	Consulta ultrarrapida e templates da Ativ_Avaliativa1
B	Python, listas, dicionarios e NumPy
C	Pandas: importacao, selecao, filtros, colunas, ordenacao
D	Estatistica descritiva
E	Graficos e interpretacao
F	GroupBy, Crosstab e tabelas cruzadas
G	Probabilidade e combinatoria
H	Binomial
I	Poisson
J	Distribuicao Normal - bloco principal
K	Exponencial
L	Checklist e templates finais

Prioridade sugerida

Nivel	Assuntos
MAXIMA	Normal; interpretacao/comparacao de graficos; Ativ_Avaliativa1; filtros; groupby; crosstab
ALTA	Binomial; Poisson; Exponencial; estatistica descritiva
BASE	Listas; NumPy; indexacao; comandos fundamentais

CONSULTA RAPIDA 1 - Traduza o enunciado para a operacao

Texto no enunciado	Matematica	Discreta (Binomial/Poisson)	Continua (Normal/Exponencial)
exatamente k	$P(X=k)$	$pmf(k)$	$P(X=k)=0$; $pdf(k)$ e densidade
ate k / no maximo k	$P(X \leq k)$	$cdf(k)$	$cdf(k)$
menos que k	$P(X < k)$	$cdf(k-1)$	$cdf(k)$
mais de k	$P(X > k)$	$sf(k)$	$sf(k)$
pelo menos k	$P(X \geq k)$	$sf(k-1)$	$sf(k)$ em continuo equivale a $\geq$
entre a e b	$P(a \leq X \leq b)$	$cdf(b) - cdf(a-1)$	$cdf(b) - cdf(a)$
fora de [a,b]	complemento	$1 - [cdf(b) - cdf(a-1)]$	$1 - [cdf(b) - cdf(a)]$
qual valor deixa q% abaixo?	quantil	$ppf(q)$	$ppf(q)$
qual valor deixa q% acima?	quantil superior	$ppf(1-q)$	$ppf(1-q)$

REGRA-MAE CDF acumula pela esquerda. SF mede a cauda direita. PPF faz o caminho inverso: recebe uma probabilidade e devolve o valor-limite.

CONSULTA RAPIDA 2 - Qual grafico usar?

Objetivo do enunciado	Grafico recomendado	O que interpretar
Distribuicao de 1 variavel numerica	Histograma	centro, dispersao, assimetria, picos, caudas
Comparar distribuicoes entre grupos	Boxplot e/ou histogramas	mediana, IQR, dispersao, outliers, forma
Frequencia de categorias	Countplot / barras	categorias mais/menos frequentes
Media/soma por categoria	Barras	comparar magnitude
Duas categorias	Barras agrupadas / crosstab	diferencas entre grupos
Composicao percentual	Barras empilhadas / pizza	proporcoes
Evolucao no tempo/ordem	Linha	tendencia, aumento, queda, estabilidade
Relacao entre 2 numericas	Dispersao	direcao, forca, forma, outliers
Relacao + tendencia linear	Dispersao + regplot	sinal e tendencia da associacao
Matriz de frequencias/intensidades	Heatmap	celulas altas/baixas e padroes
Ranking	Barras horizontais	ordem e distancia entre posicoes
Binomial/Poisson	Barras da PMF	valores mais provaveis
Normal/Exponencial	Curva de densidade	area de probabilidade e caudas

CONSULTA RAPIDA 3 - Padroes da Ativ_Avaliativa1.ipynb

Questao-modelo	Padrao	Comandos-chave
Filtrar e resumir	varias condicoes + media/mediana/DP	&, , !=, mean, median, std
Comparar 2 populacoes	filtro + boxplot	isin, boxplot
Top N	ordenar/pegar maiores + barras	nlargest, sort_values, bar/barh
2 pizzas	duas composicoes lado a lado	subplot, pie, count/sum
Agrupar e media	groupby + media + barras	groupby, mean, reset_index
Agrupar + 2 estatisticas	agg + linha	groupby().agg(), plot(kind=line)
Cruzar categorias	tabela de contingencia	pd.crosstab, bar
Proporcao por grupo	crosstab normalizado	normalize=index, *100, stacked=True

Template que vale decorar

```
# Template universal da questao de proporcoes por grupo
Tabela = pd.crosstab(
    index=df['grupo'],
    columns=df['resposta'],
    normalize='index'
)
percentual = Tabela * 100
print(percentual.round(1))
ax = percentual.plot(kind='bar', stacked=True, figsize=(9,5))
ax.set_ylabel('Percentual')
ax.set_ylim(0,100)
plt.tight_layout()
plt.show()
```

CONSULTA RAPIDA 4 - Pipeline de questao com DataFrame

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# 1) carregar
df = pd.read_csv('arquivo.csv')

# 2) inspecionar
df.head(); df.shape; df.info(); df.describe()

# 3) filtrar
sub = df[(df['A'] >= limite) & (df['B'] == 'categoria')]

# 4) resumir/agrupar
resumo = sub.groupby('grupo')['valor'].mean().reset_index()

# 5) representar
sns.barplot(data=resumo, x='grupo', y='valor')
plt.tight_layout(); plt.show()
```

1. Python, estruturas e NumPy

1.1 Listas

```
l = [1, 2, 3, 4, 5]
l[1]      # segundo elemento
l[1:4]    # indices 1,2,3 - o fim nao entra
l[:3]     # primeiros tres
l[-3:]    # ultimos tres
l.append(9)
l.insert(0, 99)
l.pop()   # remove ultimo
l.pop(0)  # remove indice 0
l.sort()
l.reverse()
l.count(12)
max(l); min(l); sum(l); len(l)
```

ARMADILHA DE SLICE Em Python, o limite final de um slice nao entra. Ex.: `l[1:4]` pega os indices 1, 2 e 3.

1.2 range, tupla, set e dicionario

```
list(range(5))      # 0,1,2,3,4
list(range(2, 10, 2)) # 2,4,6,8

t = (1, 2, 3)        # tupla: imutavel
s = {1, 3, 3, 6}     # set remove duplicatas

telefonos = {'Pedro':'11111-1111', 'Ana':'22222-2222'}
if 'Pedro' in telefonos:
    print(telefonos['Pedro'])
```

1.3 Arrays NumPy

```
import numpy as np

a = np.array([1,2,3])
np.arange(0,10)
np.linspace(-3,3,61)      # 61 pontos igualmente espacados
np.zeros((3,4))
np.ones((4,3))

b = np.arange(1,11).reshape(2,5)
b[1]      # linha 1
b[1,3]    # elemento linha 1, coluna 3
b[:, 1:4] # todas as linhas, colunas 1,2,3

a[a >= 2]      # filtro booleano
a + 10         # operacao vetorizada
```

VIEW x COPY Slices do NumPy podem ser views. Se voce alterar `arr3 = arr2[:5]`, `arr2` pode mudar tambem. Para independencia use `arr3 = arr2[:5].copy()`.

1.4 Aleatoriedade e simulacao

```
rng = np.random.default_rng()
moedas = rng.integers(0,2,size=10000)
dados = rng.integers(1,7,size=100000)

# Probabilidade empirica de sair 6
p_emp = np.mean(dados == 6)
```

Quanto maior o numero de simulacoes, maior tende a ser a proximidade entre frequencia relativa e probabilidade teorica.

2. Pandas - DataFrames e filtros

2.1 Carregamento e inspecão

```
df = pd.read_csv('arquivo.csv')
df = pd.read_csv('arquivo.csv', sep=';')
df = pd.read_csv('arquivo.csv', encoding='latin-1')

df.head()
df.shape
df.dtypes
df.info()
df.describe()
df.isnull().sum()
df['coluna'].unique()
df['coluna'].value_counts()
```

Comando	Leitura
head()	primeiros registros
shape	(linhas, colunas)
dtypes	tipo de cada coluna
info()	tipos, nulos e memoria
describe()	estatísticas numéricas
isnull().sum()	quantidade de faltantes
unique()	valores distintos
value_counts()	frequências

2.2 Seleção de colunas e linhas

```
df['salary']
df[['salary', 'height']]

# loc: rotulo/nome
df.loc['Item-1']
df.loc[['Item-1', 'Item-5'], ['Comprimento', 'Largura', 'Altura']]

# iloc: posicao numerica
df.iloc[0]
df.iloc[[0,4],[0,1,2]]
df.iloc[:5]
df.iloc[:,[0,1]]
```

2.3 Filtros - o padrao mais cobrado

```
# uma condicao
df2 = df[df['genre'] == 'Drama']

# E: cada condicao entre parenteses
df2 = df[(df['country'] != 'USA') & (df['position'] == 'G')]

# OU
df2 = df[(df['Comprimento'] >= 110) | (df['Largura'] >= 53)]

# varios valores
generos = ['Animation', 'Comedy', 'Drama', 'Horror', 'Thriller']
df2 = df[df['genre'].isin(generos)]

# excluir varios
df2 = df[~df['Region_of_Incident'].isin(['North America', 'South America'])]

# texto contem
filtro = df['LanguageHaveWorkedWith'].str.contains('Python', na=False)
df_python = df[filtro]
```

Operador	Significado
&	E
	OU
~	NAO / negar uma mascara
==	igual
!=	diferente
>=, <=	comparações

ERRO CLASSICO Em filtros Pandas, use & e |, nao and/or. Coloque cada condicao entre parenteses.

2.4 Criar, modificar e remover colunas

```
df['profit'] = df['gross'] - df['budget']
df['Volume'] = df['Comprimento'] * df['Largura'] * df['Altura']
df['Volume'] = df['Volume'].round(2)
df = df.drop(columns=['Volume'])
df = df.rename(columns={'old_name':'new_name'})
df.set_index('Country', inplace=True)

# texto numerico com virgula
df = df.replace(',', '', regex=True)
df = df.astype(float)
```

2.5 Ordenacao e Top N

```
df.sort_values(by='salary', ascending=False)

top5 = df.nlargest(5, 'profit')

top5_2015 = (
    df[df['year'] == 2015]
    .nlargest(5, 'budget')
)
```

PADRAO DE PROVA Se o enunciado disser "os 5 maiores...", pense em filtrar primeiro se necessario e depois `nlargest(5, coluna)`.

3. Estatística descritiva

3.1 Medidas de tendencia central

Media: $x_{\text{bar}} = \text{soma}(x_i) / n$

Mediana: valor central dos dados ordenados

Moda: valor mais frequente

```
df['coluna'].mean()
df['coluna'].median()
df['coluna'].mode()

import statistics as st
st.mean(lista)
st.median(lista)
st.mode(lista)
```

3.2 Amplitude, variancia e desvio-padrao

Amplitude = $\max(x) - \min(x)$

Variancia amostral: $s^2 = \text{soma}((x_i - x_{\text{bar}})^2) / (n-1)$

Desvio-padrao amostral: $s = \sqrt{s^2}$

```
df['coluna'].var()
df['coluna'].std()

st.variance(lista)
st.stdev(lista)
```


INTERPRETACAO Desvio-padrao maior significa dados mais espalhados em torno da media. Pandas std() e statistics.stdev() usam, por padrao, o desvio-padrao amostral (n-1).

3.3 Quartis, IQR e outliers

IQR = $Q3 - Q1$

```
q = st.quantiles(lista)
Q1 = q[0]
Q3 = q[2]
IQR = Q3 - Q1
```

O IQR mede a dispersao dos 50% centrais dos dados e aparece naturalmente na leitura do boxplot.



Boxplot: compare mediana, tamanho da caixa (IQR), bigodes e possiveis outliers.

3.4 Como escrever uma comparacao estatistica

- Centro: qual grupo tem media/mediana maior?
- Dispersao: qual apresenta maior DP, IQR ou amplitude?
- Formato: existe simetria ou assimetria?
- Outliers: existem pontos isolados? Eles podem afetar a media?
- Contexto: a diferenca e pequena ou visualmente relevante?


MODELO DE RESPOSTA "O grupo A apresenta mediana superior ao grupo B. Entretanto, sua caixa e mais larga, indicando maior dispersao central. O grupo B e mais concentrado e apresenta valores discrepantes superiores."

4. Visualizacao de dados - como escolher, construir e interpretar

4.1 Histograma

Use para a distribuicao de uma variavel quantitativa. O parametro bins controla o numero de intervalos.

```
df.hist(column='age', bins=8)
plt.hist(dados, bins=15)
sns.histplot(dados, bins=30, kde=True)
sns.displot(df['CPI_2014'], bins=15, kde=False)
```



Comparar histogramas: centro, amplitude, concentracao, assimetria, caudas e valores extremos.

BINS Poucos bins escondem detalhes; bins demais podem criar ruído. Se o enunciado fixa bins=15, respeite exatamente.

4.2 Boxplot

```
df.boxplot(column='tip')
df.boxplot(by='sex', column='total_bill')
sns.boxplot(data=df, x='genre', y='score')
```

- Linha da caixa = mediana
- Bordas da caixa = Q1 e Q3
- Altura/comprimento da caixa = IQR
- Pontos isolados = possíveis outliers


4.3 Barras, countplot e ranking

```
# barras simples
df.plot(x='Categoria', y='Valor', kind='bar')

# countplot: frequencia de categorias
sns.countplot(x='alive', data=df)
sns.countplot(x='sex', hue='alive', data=df)

# ranking horizontal
top15.plot(kind='barh')
```

Barras agrupadas: comparar grupos por categoria




Barras agrupadas: boa escolha para comparar dois grupos dentro de cada categoria.

4.4 Grafico de linha

Use quando existe tempo ou uma ordem natural e o foco é tendência/evolução.

```
df[['Close TSLA', 'Close AAPL']].plot()

ax = resumo['media'].plot(kind='line', marker='o', linewidth=2)
ax.set_xlabel('Tempo/ordem')
ax.set_ylabel('Media')
```



Em linha, procure aumento, queda, estabilidade, mudanças de tendência e pontos de ruptura.

4.5 Pizza e dois subplots


```
plt.pie(valores, labels=rotulos, autopct='%1.1f%%', startangle=90)
plt.axis('equal')

plt.figure(figsize=(10,6))
plt.subplot(1,2,1)
plt.pie(valores1, labels=labels1, autopct='%1.1f%%')
plt.title('Grupo 1')
plt.subplot(1,2,2)
plt.pie(valores2, labels=labels2, autopct='%1.1f%%')
plt.title('Grupo 2')
plt.tight_layout(); plt.show()
```

QUANDO USAR Pizza é adequada para partes de um total. Para comparar muitos grupos/categorias, barras costumam ser mais claras.

4.6 Dispersão e regressão visual

```
sns.regplot(x='Age', y='SBP', fit_reg=False, data=df)
sns.regplot(x='Age', y='SBP', fit_reg=True, data=df)
```



Dispersao: observe direcao, forca aparente, forma e outliers. A linha mostra a tendencia linear.


OUTLIER Um ponto extremo pode deslocar media e linha de regressao. Nao remova automaticamente: verifique se e erro ou observacao real.

4.7 Barras empilhadas, area e heatmap


```
# barras empilhadas
percentual.plot(kind='bar', stacked=True)
plt.ylim(0,100)

# area empilhada
summary.plot(kind='area', stacked=True)

# heatmap
sns.heatmap(tabela, annot=True, cmap='coolwarm')
```



Barras empilhadas em percentual: compare composicao dentro de cada grupo.



Heatmap: intensidade visual de uma tabela de frequencias ou agregacoes.

4.8 Checklist de interpretacao de qualquer grafico

Pergunta	Procure por
Onde estao os dados?	media, mediana, centro, faixa dominante
Quanto variam?	DP, IQR, amplitude, largura da distribuicao
Qual o formato?	simetria, assimetria, caudas, picos
Ha pontos estranhos?	outliers, quebras, categorias raras
Como os grupos diferem?	centro, dispersao, proporcao, tendencia
Existe relacao?	direcao positiva/negativa, forca, linearidade

5. GroupBy e Crosstab

5.1 GroupBy

```
# media por grupo
df.groupby('Company')['Sales'].mean()

# soma por grupo
df.groupby('Company')['Sales'].sum()

# duas categorias
df.groupby(['day', 'sex'])['total_bill'].mean()

# para voltar a DataFrame comum
resultado = (
    df.groupby(['day', 'sex'])['total_bill']
      .mean()
      .reset_index()
)
```

5.2 Varias estatisticas com agg

```
resumo = (
    students.groupby('studytime')
      .agg(
        quantidade=('G3', 'size'),
        media_nota=('G3', 'mean'),
        mediana=('G3', 'median'),
        minimo=('G3', 'min'),
        maximo=('G3', 'max')
      )
)
```

PADRAO Se o enunciado diz "para cada grupo, calcule X e Y", pense em `groupby(...).agg(...)`.

5.3 Crosstab - contar combinacoes

```
tabela = pd.crosstab(
    students['sex'],
    students['internet']
)

# adicionar totais
tabela = pd.crosstab(
    students['sex'], students['internet'],
    margins=True, margins_name='Total'
)
```

5.4 Crosstab com media ou soma

```
pd.crosstab(
    df['pickup_borough'], df['payment'],
    values=df['distance'], aggfunc='mean'
)

pd.crosstab(
    df['pickup_borough'], df['payment'],
    values=df['total'], aggfunc='sum'
)
```

5.5 Normalizacao - uma das maiores armadilhas

normalize	O que soma 1?	Uso
True	tabela inteira	proporcao do total global
'index'	cada linha	proporcao dentro de cada grupo da linha
'columns'	cada coluna	proporcao dentro de cada categoria da coluna

```
tabela = pd.crosstab(
    students['studytime'],
    students['higher'],
    normalize='index'
)
percentual = tabela * 100
percentual.plot(kind='bar', stacked=True)
plt.ylim(0,100)
```

QUESTAO 8 DA AVALIATIVA O normalize="index" e exatamente o padrao para responder "qual a proporcao de cada resposta dentro de cada grupo?".

6. Probabilidade e combinatoria

6.1 Probabilidade classica, empirica e complemento

$$P(A) = \text{casos favoraveis} / \text{casos possiveis}$$

$$P(A^c) = 1 - P(A)$$

Probabilidade empirica: frequencia observada / numero de experimentos. Em simulacoes grandes, tende a se aproximar da probabilidade teorica.

6.2 Uniao e intersecao

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$\text{Se independentes: } P(A \cap B) = P(A) * P(B)$$

$$\text{Se dependentes: } P(A \cap B) = P(A) * P(B | A)$$

EXEMPLO Se $P(A)=0,35$, $P(B)=0,46$ e $P(A \cup B)=0,59$, entao $P(A \cap B)=0,35+0,46-0,59=0,22$.

6.3 Permutacao e combinacao

$$\text{Permutacao/arranjo sem repeticao: } P(n,r) = n! / (n-r)!$$

A ordem importa.

$$\text{Combinacao: } C(n,r) = n! / [r!(n-r)!]$$

A ordem nao importa.

$$\text{Combinacao com repeticao: } C(n+r-1, r)$$

```
import math
math.comb(5,3)
```

COMO DECIDIR Se trocar a ordem cria um resultado diferente (presidente/vice), ordem importa. Se e apenas escolher um grupo de pessoas, a ordem nao importa.

6.4 Exemplo com cartas

Exatamente 2 ouros e 2 copas em uma mao de 4 cartas:

$$P = [C(13,2) * C(13,2)] / C(26,4) \approx 0,02247 = 2,25\%$$

CORRECAO DO MATERIAL Ha um trecho incompleto/incorreto em um notebook da aula para esse caso. O raciocinio combinatorio acima e o consistente com o problema.

7. Distribuicao Binomial

7.1 Quando usar

Condicao	Tem que valer?
Numero fixo de tentativas	sim
Dois resultados por tentativa	sim
Probabilidade p constante	sim
Tentativas independentes	sim

Exemplos: caras em 10 lancamentos, pecas defeituosas em uma amostra, acertos em perguntas de multipla escolha.


$$P(X=x) = C(n,x) * p^x * (1-p)^{(n-x)}$$

$$\text{Media} = n * p \quad | \quad \text{Variancia} = n * p * (1-p) \quad | \quad \text{DP} = \text{sqrt}(n * p * (1-p))$$

```
from scipy.stats import binom

binom.pmf(k, n, p)      # exatamente k
binom.cdf(k, n, p)      # X <= k
binom.sf(k, n, p)       # X > k
binom.sf(k-1, n, p)     # X >= k
binom.cdf(b,n,p)-binom.cdf(a-1,n,p) # a <= X <= b

binom.mean(n,p)
binom.var(n,p)
binom.std(n,p)
```



Binomial e discreta: cada barra corresponde a uma probabilidade $P(X=x)$.

PALAVRA-CHAVE "Exatamente" -> pmf. "No maximo" -> cdf. "Pelo menos" -> sf(k-1).

8. Distribuicao de Poisson

8.1 Quando usar

Use para contar quantos eventos ocorrem em um intervalo de tempo, espaco ou exposicao: chamadas por hora, falhas por semana, clientes por minuto, meteoros por intervalo.

$$P(X=x) = \exp(-\mu) * \mu^x / x!$$

$$\text{Media} = \mu \quad | \quad \text{Variância} = \mu \quad | \quad \text{DP} = \sqrt{\mu}$$

8.2 Ajuste de unidade - muito importante


Se a taxa media esta definida para um intervalo diferente do pedido, ajuste mu proporcionalmente.

$$1,81 \text{ eventos} / 30 \text{ s} \rightarrow \text{em } 60 \text{ s: } \mu = 1,81 * 2 = 3,62$$

$$1,81 \text{ eventos} / 30 \text{ s} \rightarrow \text{em } 120 \text{ s: } \mu = 1,81 * 4 = 7,24$$

```
from scipy.stats import poisson

poisson.pmf(k, mu)      # exatamente k
poisson.cdf(k, mu)      # X <= k
poisson.sf(k, mu)       # X > k
poisson.sf(k-1, mu)     # X >= k
poisson.cdf(b,mu)-poisson.cdf(a-1,mu) # a..b
poisson.ppf(0.99, mu)   # valor que deixa 99% abaixo
```



Poisson: distribuicao discreta de contagens. A forma depende da media mu.

CDF x PPF CDF: voce fornece o valor e recebe uma probabilidade. PPF: voce fornece a probabilidade acumulada e recebe o valor-limite.

9. Distribuicao Normal - BLOCO PRINCIPAL

POR QUE PRIORIZAR O professor destacou Distribuicao Normal como extremamente importante. Nos materiais ela aparece em calculos diretos, inversos, tolerancias, simulacoes, precisao de medicao, graficos e interpretacao.

9.1 Como reconhecer

- Variavel geralmente continua: peso, altura, temperatura, volume, comprimento, diametro, tempo de vida.
- Curva simetrica em forma de sino.
- Media, mediana e moda coincidem na Normal teorica.
- A area total sob a curva e 1.
- A distribuicao e determinada por media (μ) e desvio-padrao (σ).


$$Z = (X - \mu) / \sigma$$

z diz quantos desvios-padrao X esta acima (+) ou abaixo (-) da media.

EXEMPLO DE Z $\mu=150$, $\sigma=2$, $X=153 \rightarrow z=(153-150)/2=1,5$. O valor esta 1,5 desvios-padrao acima da media.


9.2 Regra 68-95-99,7%

Intervalo em torno da media	Area aproximada
$\mu \pm 1 \sigma$	68%
$\mu \pm 2 \sigma$	95%
$\mu \pm 3 \sigma$	99,7%




A probabilidade em uma Normal e uma area sob a curva. Aqui, a regio central entre 98 e 102 para $\mu=100$ e $\sigma=2$.

9.3 Efeito de mu e sigma no grafico



Aumentar sigma espalha a distribuicao: a curva fica mais larga e mais baixa.



Alterar mu desloca o centro horizontalmente sem mudar a dispersao quando sigma permanece fixo.

Mudanca	Efeito visual
mu aumenta	curva desloca para a direita
mu diminui	curva desloca para a esquerda
sigma aumenta	curva mais larga/achatada
sigma diminui	curva mais estreita/alta

9.4 O comando central: norm.cdf

$$P(X \leq x) = \text{CDF}(x)$$

```
from scipy.stats import norm
p = norm.cdf(x, loc=mu, scale=sigma)
```

MEMORIA VISUAL CDF = area acumulada a esquerda do ponto x.

9.5 Cauda direita: norm.sf

$$P(X > x) = \text{SF}(x) = 1 - \text{CDF}(x)$$

```
p = norm.sf(x, loc=mu, scale=sigma)
# equivalente a:
p = 1 - norm.cdf(x, loc=mu, scale=sigma)
```

9.6 Probabilidade entre dois valores

$$P(a < X < b) = CDF(b) - CDF(a)$$

```
p = (
  norm.cdf(b, loc=mu, scale=sigma)
  - norm.cdf(a, loc=mu, scale=sigma)
)
```

EXEMPLO Para $X \sim N(150, 2)$, $P(148 < X < 152) = \text{cdf}(152) - \text{cdf}(148) \approx 0,6827$, ou 68,27%.

9.7 Fora de um intervalo / peças fora da tolerancia

$$P(\text{fora}) = 1 - P(a \leq X \leq b)$$

```
aceitavel = norm.cdf(b, mu, sigma) - norm.cdf(a, mu, sigma)
defeito = 1 - aceitavel
```

PADRAO DE ENUNCIADO "Peca e aceita entre a e b. Qual percentual sera rejeitado?" -> calcule a area aceita e use o complemento.

9.8 Converter probabilidade em quantidade

```
quantidade = round(probabilidade * N)
```

Se a probabilidade for 0,586 em uma populacao de 500, a estimativa e $0,586 \cdot 500 = 293$ individuos.

9.9 PPF - quando o limite e desconhecido

$$x = PPF(q) \Leftrightarrow P(X \leq x) = q$$

```
x = norm.ppf(q, loc=mu, scale=sigma)
```

Enunciado	q usado no ppf
"1% abaixo do limite"	0.01
"95% abaixo"	0.95
"5% acima"	0.95
"1% acima"	0.99

EXEMPLO GARANTIA Se somente 1% das TVs deve falhar antes da garantia e $X \sim N(8,2; 1,1)$, use $\text{norm.ppf}(0.01, 8.2, 1.1) \approx 5,64$ anos.

9.10 PDF x CDF - pegadinha conceitual

```
norm.pdf(x, mu, sigma) # densidade/altura da curva
norm.cdf(x, mu, sigma) # probabilidade acumulada ate x
```

IMPORTANTE Em variavel continua, $P(X=x)=0$. O pdf(x) nao e "a probabilidade exata do ponto"; e densidade. Probabilidades sao areas em intervalos.

9.11 Precisao de medicaao / arredondamento

Se uma balanca registra centesimos e mostra exatamente 64,00 kg, o peso verdadeiro que arredonda para esse registro ocupa um pequeno intervalo.

Registro 64,00 -> aproximadamente $63,995 \leq X < 64,005$

```
p_64 = (
    norm.cdf(64.005, mu, sigma)
    - norm.cdf(63.995, mu, sigma)
)

# "menos de 64,00 registrado"
p_menos = norm.cdf(63.995, mu, sigma)

# "64,00 ou menos registrado"
p_ate_64 = norm.cdf(64.005, mu, sigma)
```

POR QUE ISSO E DIFICIL A variavel teorica e continua, mas o instrumento discretiza por arredondamento. O intervalo de meia unidade de precisao corrige essa traducao.

9.12 Template completo para desenhar a Normal

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import norm

mu = 100
sigma = 2
x = np.linspace(mu-4*sigma, mu+4*sigma, 1000)
y = norm.pdf(x, loc=mu, scale=sigma)

plt.figure(figsize=(10,5))
plt.plot(x,y)
plt.axvline(mu, linestyle='--', label='Media')
plt.xlabel('X')
plt.ylabel('Densidade')
plt.title('Distribuicao Normal')
plt.legend(); plt.grid(); plt.show()
```

9.13 Destacar a area pedida no grafico

```
# intervalo central
plt.fill_between(
    x, y,
    where=((x >= a) & (x <= b)),
    alpha=0.3
)

# cauda direita
plt.fill_between(x, y, where=(x >= limite), alpha=0.3)

# cauda esquerda
plt.fill_between(x, y, where=(x <= limite), alpha=0.3)
```

ESTRATEGIA DE PROVA Antes de calcular, desenhe a curva e pinte mentalmente a regioao. Se a area esta a direita, SF tende a ser natural; se e central, diferenca de CDFs; se o limite e desconhecido, PPF.

9.14 Roteiro de decisao para qualquer questao Normal

Passo	Pergunta	Acao
1	Quais sao mu e sigma?	identifique no texto
2	A pergunta da um valor x ou uma probabilidade q?	x -> CDF/SF; q -> PPF
3	Area e esquerda, direita, entre ou fora?	marque a regioao
4	Ha arredondamento/precisao do instrumento?	ajuste limites em meia unidade da precisao
5	Pede numero de individuos?	probabilidade * N
6	Pede grafico?	norm.pdf para a curva + fill_between para a area

9.15 Mini-exemplos resolvidos por padrao

Caso A - menor que x:

```
# X~N(50, 4), P(X<56)
p = norm.cdf(56, 50, 4)
```

Caso B - maior que x:

```
# P(X>56)
p = norm.sf(56, 50, 4)
```

Caso C - entre a e b:

```
# P(46<X<54)
p = norm.cdf(54,50,4) - norm.cdf(46,50,4)
```

Caso D - limite superior para 5% acima:

```
# P(X>x)=0.05 => P(X<=x)=0.95
x = norm.ppf(0.95, 50, 4)
```

10. Distribuicao Exponencial

10.1 Quando usar e relacao com Poisson

Poisson	Exponencial
quantos eventos em um intervalo	quanto tempo ate o proximo evento
variavel discreta de contagem	variavel continua de tempo
parametro medio de contagem μ	taxa λ / media de espera $1/\lambda$


Media = $1/\lambda$ | Variancia = $1/\lambda^2$ | DP = $1/\lambda$

CUIDADO COM SCIPY/NUMPY O parametro scale da Exponencial e a media $1/\lambda$, nao λ .

```
from scipy.stats import expon

lamb = 0.36
media = 1/lamb

expon.cdf(t, scale=media)           # T <= t
expon.sf(t, scale=media)            # T > t
expon.cdf(b,scale=media)-expon.cdf(a,scale=media) # a<T<b
expon.ppf(0.95, scale=media)        # tempo que deixa 95% abaixo
```



Exponencial: maior densidade perto de zero e cauda longa a direita.

10.2 Ajustando a taxa

Se chegam em media 3,6 clientes a cada 10 minutos:

$\lambda = 3,6 / 10 = 0,36$ cliente/minuto

media de espera = $1/0,36 \approx 2,78$ minutos

10.3 Simulacao

```
tempos = np.random.exponential(scale=media, size=10000)
sns.histplot(tempos, bins=40)
np.mean(tempos)
np.std(tempos)
```

Na Exponencial teorica, media e desvio-padrao sao iguais a $1/\lambda$.

11. Templates finais prontos para adaptar

11.1 Filtrar + estatísticas

```
sub = df[
    (df['A'] >= valor_min) &
    (df['B'] != 'categoria_excluida')
]

media = sub['Y'].mean()
mediana = sub['Y'].median()
dp = sub['Y'].std()
print(media, mediana, dp)
```

11.2 Comparar dois grupos com boxplot

```
grupos = ['Grupo A', 'Grupo B']
sub = df[df['grupo'].isin(grupos)]
sns.boxplot(data=sub, x='grupo', y='valor')
plt.tight_layout(); plt.show()
```

11.3 Top 5 + grafico

```
top5 = df.nlargest(5, 'valor').sort_values('valor')
top5.plot(x='nome', y='valor', kind='barh', legend=False)
plt.tight_layout(); plt.show()
```

11.4 GroupBy + duas estatísticas + linha

```
resumo = (
    df.groupby('grupo')
    .agg(
        quantidade=('valor', 'size'),
        media=('valor', 'mean')
    )
)
ax = resume['media'].plot(kind='line', marker='o')
ax.set_xlabel('Grupo')
ax.set_ylabel('Media')
plt.tight_layout(); plt.show()
```

11.5 Crosstab + barras agrupadas

```
tab = pd.crosstab(df['cat1'], df['cat2'])
tab.plot(kind='bar')
plt.tight_layout(); plt.show()
```

11.6 Crosstab percentual + barras empilhadas

```
tab = pd.crosstab(df['grupo'], df['resposta'], normalize='index')*100
ax = tab.plot(kind='bar', stacked=True)
ax.set_ylim(0,100)
ax.set_ylabel('Percentual')
plt.tight_layout(); plt.show()
```

12. Armadilhas e correcoes importantes

Armadilha	Correcao
Usar and/or em filtros Pandas	Use & e com cada condicao entre parenteses.
Confundir loc e iloc	loc usa rotulos; iloc usa posicoes inteiras.
Confundir pdf com probabilidade pontual na Normal	pdf e densidade; probabilidades sao areas.
Usar cdf(k) para "pelo menos k" na discreta	Use sf(k-1).
Usar cdf(a) na diferenca discreta a..b	Use cdf(b)-cdf(a-1).
Esquecer de ajustar mu da Poisson ao intervalo	Escalone a media proporcionalmente ao tempo/exposicao.
Passar lambda em scale da Exponencial	Use scale=1/lambda.
Interpretar outlier como erro automaticamente	Investigue antes de remover.
Comparar grafico so por "maior/menor"	Fale de centro, dispersao, forma e outliers.
Esquecer arredondamento da medida continua	Use meia unidade da precisao, quando aplicavel.
Copiar celula que depende de variavel antiga	Reatribua ax/resumo no mesmo bloco para codigo independente.

12.1 Observacoes especificas encontradas nos materiais

- Problema das cartas: use $[C(13,2)*C(13,2)]/C(52,4)$ para 2 ouros e 2 copas.
- Em um notebook de linguagens, a logica de "nenhuma das anteriores" e algumas contagens hardcoded nao sao boas referencias para copiar sem revisar.
- Se um enunciado pedir especificamente o ano de 2016, selecione apenas essa coluna antes do grafico, em vez de plotar varias colunas.
- Na questao de linha da atividade avaliativa, atribua `ax = ...plot(...)` antes de chamar `ax.set_xlabel/ax.set_ylabel`.

12.2 Checklist antes de entregar uma questao

1. Confirme se voce filtrou exatamente as linhas pedidas.
2. Confira se usou E (&) ou OU (|) corretamente.
3. Verifique unidade e intervalo temporal.
4. Confira se a pergunta e exatamente/ate/mais de/pelo menos/entre.
5. Rotule titulo e eixos do grafico.
6. Se comparou grupos, escreva uma interpretacao textual.
7. Se e Normal, confira se a area calculada corresponde ao lado pintado mentalmente.
8. Se e PPF, confirme se a probabilidade fornecida e a acumulada pela esquerda.
9. Se e percentual, multiplique a proporcao por 100 quando necessario.
10. Execute a celula de forma independente e verifique se nao depende de variavel criada muito antes.

FOLHA FINAL - O que procurar em 20 segundos

Se aparecer...	Pense imediatamente em...
"exatamente" em Binomial/Poisson	pmf
"ate", "no maximo"	cdf
"mais de"	sf
"pelo menos" em discreta	sf(k-1)
"entre"	diferenca de CDFs
"qual valor deixa 95% abaixo"	ppf(0.95)
"5% acima"	ppf(0.95)
"comparar distribuicoes"	boxplot/histograma
"relacao entre duas numericas"	scatter/regplot
"frequencia por categoria"	countplot/barras
"evolucao"	linha
"ranking/top"	nlargest/sort_values + barh
"proporcao dentro de cada grupo"	crosstab normalize=index
"para cada grupo calcule media/quantidade"	groupby + agg
"fora da tolerancia"	1 - probabilidade dentro
"instrumento arredonda em 0,01"	limites +/-0,005

Comandos que valem decorar

```
# DataFrames
isin | str.contains | nlargest | sort_values | groupby | agg | crosstab

# Estatistica
a.mean() | a.median() | a.std() | a.var()

# Graficos
hist | boxplot | bar | barh | line | scatter/regplot | pie | heatmap

# Distribuicoes
binom.pmf/cdf/sf/ppf
poisson.pmf/cdf/sf/ppf
norm.pdf/cdf/sf/ppf
expon.pdf/cdf/sf/ppf
```

IDEIA CENTRAL A prova tende a mudar o contexto e os nomes das colunas, mas os padroes se repetem. Reconheca o padrao, copie o template correspondente, substitua variaveis e interprete o resultado.

Fim do guia. Boa prova.